

INTELIGÊNCIA ARTIFICIAL

**Pré-processamento dos dados e Redução
da dimensionalidade**

Karina Valdivia Delgado

Dados reais

Em geral são:

- incompletos: faltam valores e/ou atributos (salário = “ “).
- ruidosos: contêm erros e/ou outliers (salário = -1500).
- inconsistentes: apresentam discrepâncias.

Isso, pode prejudicar o desempenho do nosso modelo.

Pré-processamento dos dados

- Limpeza de dados:
 - lidar com valores ausentes (missing values), dados ruidosos, outliers e inconsistências.
- Identificação de vazamento de dados
- Integração de dados de múltiplos bancos de dados e arquivos.
- Transformação de dados: normalização e agregação.
- Discretização.
- Balanceamento de classes


Tratamento de valores ausentes

Formas de eliminação de valores ausentes:

- Eliminar instâncias/atributos com valores ausentes;
 - Porém, a perda de dados pode ser considerável.
- Preenchimento de valores (imputação)
 - Por um valor desconhecido
 - Por uma constante. Ex.: média ou moda do atributo ou dos objetos da mesma classe
 - Desconsidera a relação entre atributos da base de dados
 - Por valores que tentem preservar as relações entre atributos da base de dados
 - Usando um algoritmo de aprendizado.

Dados ruidosos

- Em regressão os ruídos são os outliers, os pontos fora da curva e que seria bom remover.
- Em classificação às vezes são os outliers que queremos detectar. Ex: detectar transações fraudulentas.




Vazamento de dados (data leakage)

Alguma característica (atributo) usado no treinamento do algoritmo tem a resposta (a informação que estamos tentando prever)

Normalização

- As unidades de medida afetam a distância entre os objetos.
- Atributos com escala mais ampla tendem a ter maior peso nos cálculos de distâncias.
 - Isso representa uma forma de pré-ponderação dos dados.
- Normalização busca eliminar esse efeito, assumindo que isso pode ser uma simples consequência do uso de unidades de medida específicas.



Normalização

- Algumas estratégias são:

- Reescala Linear $[0,1]$:
$$l_{ij} = \frac{x_{ij} - \min(\mathbf{a}_j)}{\max(\mathbf{a}_j) - \min(\mathbf{a}_j)}$$

- Padronização por escore z :
$$z_{ij} = \frac{x_{ij} - \mu_{\mathbf{a}_j}}{\sigma_{\mathbf{a}_j}}$$

Discretização

É realizada quando é necessário transformar variáveis contínuas em variáveis discretas (inteiras ou categóricas).

- De contínua para inteira: aplicar round/floor/ceil
- De intervalares/racionais para categóricas. Por exemplo para árvores de decisão.
 - Discretização levando em consideração o rótulo: discretizar os intervalos que melhor auxiliem na discriminação das classes.

Balanceamento de classes

Quando tenho muito mais exemplos de uma classe do que a outra.


Estratégias de balanceamento:

- Undersampling: diminui a classe majoritária
 - Random Undersampling
- Oversampling: aumenta a classe minoritária
 - Random Oversampling
 - Synthetic Minority Oversampling Technique (SMOTE)
- Híbridas
 - SMOTE seguido de ligações de Tomek

Redução da dimensionalidade

Finalidades:

- Descartar características irrelevantes
- Fugir da maldição da dimensionalidade: dependendo do tamanho da nossa amostra de treinamento, ter variáveis demais pode ser ruim. Existe um ponto em que aumentar a quantidade de atributos não ajuda mais na queda da mistura de classes e o erro do classificador começa a aumentar por causa do erro de estimação dos parâmetros.



Redução da dimensionalidade

Estratégias:

- Fusão de características: as características são combinadas para criar um conjunto novo e menor de características
 - PCA (Análise de Componentes Principais)
- Seleção de características

Seleção de características

- Dadas N características, desejamos escolher um subconjunto contendo D características tal que seja melhor que outros subconjuntos.
- Problema: existem 2^N subconjuntos possíveis.
- O problema de seleção de características não é trivial pois o número de subconjuntos possíveis a serem avaliados para poder encontrar qual é o melhor, cresce exponencialmente.

INTELIGÊNCIA ARTIFICIAL

**Pré-processamento dos dados e Redução
da dimensionalidade**

Karina Valdivia Delgado