


INTELIGÊNCIA ARTIFICIAL


Métodos de avaliação de classificadores

Karina Valdivia Delgado

Aprendizado a partir de uma amostra



Aprendizado a partir de uma amostra



Erro


Avaliando um classificador

- Como estimar o erro e assim comparar diferentes algoritmos de classificação?
- Taxa de erro/taxa de acerto (acurácia)
- Se temos uma determinada amostra rotulada, então podemos utilizar esse rótulo para testar o classificador e estimar o erro.

Avaliando um classificador

Estimativa do erro

- Podemos separar uma parte da amostra para treinamento e a outra parte para teste.
- Os erros encontrados na amostra de teste são uma estimativa do erro.




Avaliando um classificador

Estimativa do erro

Características desejadas dessas amostras:

- grandes o suficiente
- independentes: não deve haver exemplos em comum entre o conjunto de treinamento e o conjunto de teste.

Como faço a estimação de erro a partir de uma amostra dada?



Métodos de estimação de erro de um classificador

Métodos de amostragem:

- Holdout
- Amostragem aleatória
 - r-fold cross-validation
 - r-fold stratified cross-validation
 - Leave-one-out
 - Bootstrap


Holdout

Divide a amostra (os exemplos) em duas partes:

- uma porcentagem de exemplos p para treinamento
- $(1-p)$ para teste

Exemplo: $p = \frac{2}{3}$ e $(1-p) = \frac{1}{3}$

Desvantagem: Diferentes divisões podem dar diferentes estimativas




Amostragem Aleatória

- **L hipóteses** são induzidas a partir de cada um dos **L conjuntos de treinamento**.
- O erro final é a média dos erros de todas as hipóteses induzidas e calculados em conjuntos de teste independentes e extraídos aleatoriamente.
- **Métodos de amostragem aleatória**
 - r-fold cross-validation
 - r-fold stratified cross-validation
 - Leave-one-out
 - Bootstrap


r-fold cross-validation

- Os exemplos são aleatoriamente divididos em r partições (folds) de tamanho n/r .
- Os exemplos de $(r-1)$ folds são usados no treinamento e os classificadores obtidos são testados com o fold que restou.
- O processo é repetido r vezes, sendo que em cada repetição um fold diferente é usado para teste.



r-fold cross-validation

- Os exemplos são aleatoriamente divididos em r partições (folds) de tamanho n/r .
- Os exemplos de $(r-1)$ folds são usados no treinamento e os classificadores obtidos são testados com o fold que restou.
- O processo é repetido r vezes, sendo que em cada repetição um fold diferente é usado para teste.



- O erro do cross-validation é a média dos erros dos r folds.

r-fold cross-validation

- Suponha que foi usado o método de amostragem 5-fold cross-validation para estimar a acurácia de um algoritmo A em um conjunto de exemplos T e desejamos calcular a média e desvio padrão.

Acurácia do algoritmo A nos r-folds:

[0.91208791, 0.86813187, 0.93406593, 0.92307692, 0.9010989]

Média: 0.91 Desvio padrão: 0.023

r-fold cross-validation

Suponha que deseja-se comparar três algoritmos A, B e C com médias e desvio padrão da acurácia iguais a:

Modelo A: **MLP** | Média: 0.92 | Desvio: 0.029

Modelo B: **LinearRegression** | Média: 0.76 | Desvio: 0.023

Modelo C: **Decision Tree** | Média: 0.93 | Desvio: 0.23


Para decidir qual deles é melhor que o outro, pode-se aplicar algum teste estatístico apropriado (com grau de confiança de 95%, por exemplo).

r-fold stratified cross-validation

- Similar ao cross-validation, porém a distribuição das classes do conjunto original deve ser preservada em cada fold.


Leave-one-out

- Caso especial de cross-validation.
- Para uma amostra de tamanho n , $n-1$ exemplos são usados no treinamento e os classificadores obtidos são testados com o exemplo que restou.
- O processo é repetido n vezes, sendo que em cada repetição um exemplo diferente é usado para teste.



Leave-one-out

- Caso especial de cross-validation.
- Para uma amostra de tamanho n , $n-1$ exemplos são usados no treinamento e os classificadores obtidos são testados com o exemplo que restou.
- O processo é repetido n vezes, sendo que em cada repetição um exemplo diferente é usado para teste.
- O erro é a soma dos erros dos testes para cada exemplo dividido por n .
- Usado apenas quando o conjunto de exemplos é pequeno.




Bootstrap

- São geradas várias **amostras com reposição** de tamanho m a partir do conjunto original de tamanho n ($m < n$, $m = n$ ou $m > n$)
- Funciona bem quando a amostra original é pequena

Bootstrap: caso simples ($m=n$)

O conjunto de treinamento é formado por n exemplos extraídos aleatoriamente com reposição.

Os exemplos que não pertencem ao conjunto de treinamento serão parte do conjunto de teste.



INTELIGÊNCIA ARTIFICIAL

Métodos de avaliação de classificadores

Karina Valdivia Delgado