

INTELIGÊNCIA ARTIFICIAL

Medidas de avaliação de classificadores

Karina Valdivia Delgado

Matriz de confusão

- Para avaliar o desempenho de um classificador é útil calcular a “matriz de confusão” $M: N_y \times N_y$, em que N_y denota o número de classes.
- As **linhas** de M representam os **rótulos da classe verdadeira** (classe original) e as **colunas** representam a saída do classificador (**classe predita**).
- Na classificação binária $N_y = 2$.

- M_{ij} = número de amostras da classe i que foram preditas como sendo da classe j

Multi-Class Confusion Matrix						
Actual	Predicted					
	Classes	A	B	C	D	Total
	A	50	10	30	20	110
	B	15	20	30	15	80
	C	20	10	30	40	100
	D	15	15	30	50	110
	Total	100	55	120	125	800

Matriz de confusão

As quatro entradas na matriz correspondem a:

- **TP**: número de verdadeiros positivos ou classificações positivas corretas
- **FN**: número de falsos negativos ou classificações positivas perdidas
- **FP**: número de falsos positivos ou classificações positivas incorretas
- **TN**: número de verdadeiros negativos ou rejeições corretas.

		Classe Predita	
		-	+
Classe Original	-	TN	FP
	+	FN	TP

Matriz de confusão

N: amostras negativos

P: amostras positivos

$N + P = m$

$N = TN + FP$

$P = TP + FN$

		Classe Predita	
		-	+
Classe Original	-	TN	FP
	+	FN	TP

Acurácia e erro

- A acurácia da classificação (**ACC**) é definida como a razão entre as amostras corretamente classificadas e o número total de amostras, isto é:

$$\frac{TP + TN}{TP + FN + FP + TN} = \frac{TP + TN}{m}$$

- A taxa de **erro** é:

$$1 - ACC$$

N: amostras negativos

P: amostras positivos

$$N + P = m$$

$$N = TN + FP$$

$$P = TP + FN$$

Precisão e especificidade

- **Precisão**: a razão entre o número de verdadeiros positivos e todos os que foram preditos como positivos

$$\frac{TP}{TP+FP}$$

exemplos que foram
preditos como positivos

- **Especificidade**: é a fração de negativos corretamente classificados como negativos

$$\frac{TN}{TN+FP} = \frac{TN}{N}$$

exemplos que são
genuinamente da classe
negativa

TPR e FPR

- **TPR** (true positive rate ou **sensitividade** ou taxa de recall ou **revocação**) é a fração de positivos corretamente identificados como positivos

exemplos que são genuinamente da classe positiva

$$\frac{\text{TP}}{\text{TP} + \text{FN}} = \frac{\text{TP}}{P}$$

- **FPR** (false positive rate ou 1- especificidade) é a razão entre os incorretamente classificados como positivos e todos os que são da classe original negativa.

exemplos que são genuinamente da classe negativa

$$\frac{\text{FP}}{\text{TN} + \text{FP}} = \frac{\text{FP}}{N}$$

F-measure

$$\frac{2 * \text{precisão} * \text{revocac\~ao}}{\text{precis\~ao} + \text{revocac\~ao}}$$

Exemplo: Matriz de confusão para a classe *cancer* = yes (+) e *cancer* = no (-).

		classe predita			
		<i>Classes</i>	<i>yes</i>	<i>no</i>	<i>Total</i>
classe original	<i>yes</i>		90	210	300
	<i>no</i>		140	9560	9700
	Total		230	9770	10,000

- acurácia:
 - sensibilidade ou revocação:
- especificidade:
 - precisão:

acurácia = (TP +TN)/m

precisão =TP/(TP+FP)
TPR ou sensibilidade ou recall = TP/P
especificidade = TN/N
FPR = FP/N

P = TP + FN
N= TN + FP

Exemplo: Matriz de confusão para a classe *cancer* = *yes* (+) e *cancer* = *no* (-).

		classe predita		
classe original	Classes	<i>yes</i>	<i>no</i>	Total
	<i>yes</i>	90	210	300
	<i>no</i>	140	9560	9700
	Total	230	9770	10,000

- acurácia: 96,50%
- sensibilidade ou revocação: 30%
- especificidade: 98,56%
- precisão: 39,13%

$acurácia = (TP + TN)/m$

$precisão = TP/(TP + FP)$

$TPR \text{ ou } sensibilidade \text{ ou } recall = TP/P$

$especificidade = TN/N$

$FPR = FP/N$

$P = TP + FN$

$N = TN + FP$

- Sensibilidade: apenas 30% dos exemplos positivos foram corretamente classificados como positivos pelo algoritmo
- Precisão: dos exemplos que o algoritmo classificou como sendo positivos, apenas 39,13% de fato eram positivos.


Curva ROC

- Curva ROC (“receiver operating characteristic”) é um gráfico que mostra a proporção de verdadeiros positivos (TPR) versus a proporção de falsos positivos (FPR) quando algum parâmetro do classificador é variado.
- Quando se varia algum parâmetro do classificador (e.g., o **limiar**), obtém-se diferentes números de TP e FP.
- A curva ROC permite comparar diferentes classificadores.

ROC curve

TPR ou sensibilidade
ou recall = TP/P
FPR = FP/N


- Classificadores que só fornecem a classe são representados como um único ponto.



ROC curve

TPR ou **sensibilidade**
ou **recall** = TP/P
FPR = FP/N


- O **classificador perfeito (ideal)** ocupa o canto superior esquerdo (TPR=1 e FPR=0)
- A e C' são classificadores que executam melhor que o **classificador aleatório** (adivinhação)
- B executa nos níveis do aleatório.
- C executa significativamente pior que o aleatório.



ROC curve: classificador aleatório

TPR ou **sensibilidade**
ou **recall** = TP/P
FPR = FP/N

- Cada ponto (p,p) pode ser obtido pela previsão da classe positiva com probabilidade p e da classe negativa com probabilidade $1 - p$.
- (0,0) nunca classifica um exemplo como positivo $\Rightarrow$ $TP=0$ $FP=0 \Rightarrow$ $TPR=0$ $FPR=0$
- (1,1) sempre classifica um exemplo como positivo $\Rightarrow$ $TP=P$ e $FP=N$




Classificador A		
+	-	
TP = 32	FN = 48	POS = 80
FP = 16	TN = 24	NEG = 40
		N = 120

Classificador B		
+	-	
TP = 48	FN = 32	POS = 80
FP = 24	TN = 16	NEG = 40
		N = 120

ROC curve

TPR ou **sensibilidade**
ou **recall** = TP/P
FPR = FP/N

- Modelos próximos ao canto inferior esquerdo são **conservadores**: eles fazem uma classificação positiva somente se têm grande segurança na classificação. Como consequências, cometem poucos erros de falsos positivos, e têm baixas taxas de verdadeiros positivos;
- Modelos próximos ao canto superior direito são **liberais**: eles predizem a classe positiva com maior frequência, de tal maneira que classificam a maioria dos exemplos positivos corretamente, mas também possuem altas taxas de falsos positivos.



slide da profa. Sarajane Marques Peres

ROC curve


TPR ou sensibilidade
ou recall = TP/P
FPR = FP/N

- Para classificadores que fornecem um valor contínuo (uma probabilidade ou um score) podemos definir um limiar para classificar o exemplo como positivo ou negativo.
- Por exemplo, o algoritmo pode devolver 0,7 de probabilidade que a imagem corresponda a um gato para uma instância dada.
- Para criar a curva vamos variar o limiar. Teoricamente basta variar o limiar de $-\infty$ a $+\infty$. No caso de probabilidades de 0 a 1. Na prática vou variar o limiar para cada probabilidade/score apresentado por cada instância de teste.
- Os exemplos são ordenados para simular a escolha de vários limiares de decisão de classificação.

Curva ROC

TPR ou **sensibilidade**
ou **recall** = TP/P
FPR = FP/N

Inst#	Class	Score	Inst#	Class	Score
1	p	.9	11	p	.4
2	p	.8	12	n	.39
3	n	.7	13	p	.38
4	p	.6	14	n	.37
5	p	.55	15	n	.36
6	p	.54	16	n	.35
7	n	.53	17	p	.34
8	n	.52	18	n	.33
9	p	.51	19	p	.30
10	n	.505	20	n	.1




Simulamos o que acontece se o classificador utilizaria os scores como limiar
Se o score é maior a 0.9 é classificado como positivo, como não tenho nenhum
exemplo então TP=0 FP=0

Pattern Recognition Letters. 27 (2006). 861-874.

Curva ROC

TPR ou **sensibilidade**
ou **recall** = TP/P
FPR = FP/N

Inst#	Class	Score	Inst#	Class	Score
1	p	.9	11	p	.4
2	p	.8	12	n	.39
3	n	.7	13	p	.38
4	p	.6	14	n	.37
5	p	.55	15	n	.36
6	p	.54	16	n	.35
7	n	.53	17	p	.34
8	n	.52	18	n	.33
9	p	.51	19	p	.30
10	n	.505	20	n	.1



Se score ≥ 0.9 é classificado como positivo

TP=1 $\Rightarrow$ TPR=0,1


FP=0 $\Rightarrow$ FPR=0

Pattern Recognition Letters. 27 (2006). 861-874.

Curva ROC

TPR ou sensibilidade
ou recall = TP/P
FPR = FP/N

Inst#	Class	Score	Inst#	Class	Score
1	p	.9	11	p	.4
2	p	.8	12	n	.39
3	n	.7	13	p	.38
4	p	.6	14	n	.37
5	p	.55	15	n	.36
6	p	.54	16	n	.35
7	n	.53	17	p	.34
8	n	.52	18	n	.33
9	p	.51	19	p	.30
10	n	.505	20	n	.1



Se score ≥ 0.8 é classificado com positivo

TP=2 $\Rightarrow$ TPR=0,2


FP=0 $\Rightarrow$ FPR=0

Pattern Recognition Letters. 27 (2006). 861-874.

Curva ROC

TPR ou sensibilidade
ou recall = TP/P
FPR = FP/N

Inst#	Class	Score	Inst#	Class	Score
1	p	.9	11	p	.4
2	p	.8	12	n	.39
3	n	.7	13	p	.38
4	p	.6	14	n	.37
5	p	.55	15	n	.36
6	p	.54	16	n	.35
7	n	.53	17	p	.34
8	n	.52	18	n	.33
9	p	.51	19	p	.30
10	n	.505	20	n	.1




Se score ≥ 0.7 é classificado como positivo
TP=2 $\Rightarrow$ TPR=0,2
FP=1 $\Rightarrow$ FPR=0,1

Pattern Recognition Letters. 27 (2006). 861-874.

ROC curve: escolha de um limiar


- Posso fazer uma inspeção visual de quando estou disposto a abrir mão de um lado para ganhar do outro.



Curva ROC: escolha de um limiar


Alguns critérios:

- Youden: escolher o que apresenta maior distância (no eixo y) da diagonal (que representa uma classificação totalmente ao acaso (na figura: ponto P)
- 01: escolher o mais próximo do ponto (0,1) (na figura: ponto O)




ROC curve

- A curva ROC permite comparar classificadores.



Area under de curve AUC

- É uma medida da qualidade de um classificador.
- Quanto maior a AUC melhor é o classificador.



INTELIGÊNCIA ARTIFICIAL

Medidas de avaliação de classificadores

Karina Valdivia Delgado