

INTELIGÊNCIA ARTIFICIAL


Interpretação probabilística da Regressão Linear

Regressão Logística

Karina Valdivia Delgado

Slides baseados nas notas do prof. Andrew Ng

Exemplo de aprendizado supervisionado



Como representar h ?

Exemplo de aprendizado supervisionado

Living area (feet ²)	#bedrooms	Price (1000\$s)
2104	3	400
1600	3	330
2400	3	369
1416	2	232
3000	4	540
$\vdots$	$\vdots$	$\vdots$

θ : parâmetros / pesos

n : número de atributos

m : número de exemplos de treinamento

x : atributos

y : rótulo

$(x^{(i)}, y^{(i)})$: i -ésimo exemplo de treinamento

$$h(x) = \sum_{i=0}^n \theta_i x_i = \theta^T x$$


Na regressão linear:

$$h = \theta_0 + \theta_1 x_1 + \theta_2 x_2 \quad x_0 = 1$$
$$\theta = \begin{bmatrix} \theta_0 \\ \theta_1 \\ \theta_2 \end{bmatrix} \quad x = \begin{bmatrix} x_0 \\ x_1 \\ x_2 \end{bmatrix}$$

Função de custo

- Considere que temos apenas um atributo x_1
- Ou seja temos dois parâmetros $\theta_0 \theta_1$
- Desejamos minimizar $J(\theta)$, precisamos de um algoritmo que permite encontrar o valor desses parâmetros

$$J(\theta) = \frac{1}{2} \sum_{i=1}^m (h_{\theta}(x^{(i)}) - y^{(i)})^2$$



Algoritmos iterativos que minimiza $J(\theta)$ e que permite encontrar o valor dos parâmetros θ

1. Batch gradient descent
2. Stochastic gradient descent

Regressão linear

$$h(x) = \sum_{i=0}^n \theta_i x_i = \theta^T x$$

$$J(\theta) = \frac{1}{2} \sum_{i=1}^m (h_{\theta}(x^{(i)}) - y^{(i)})^2$$

Porque regressão linear com uma função de custo de mínimos quadrados é uma escolha razoável?

Para isso, introduzimos a seguir uma interpretação probabilística.

Mostraremos que a regressão de mínimos quadrados é o mesmo que encontrar a estimativa de máxima verossimilhança de θ quando os erros são gaussianos.

Regressão linear

$$h(x) = \sum_{i=0}^n \theta_i x_i = \theta^T x$$

$$J(\theta) = \frac{1}{2} \sum_{i=1}^m (h_{\theta}(x^{(i)}) - y^{(i)})^2$$

Porque regressão linear com uma função de custo de mínimos quadrados é uma escolha razoável?

Suponha que os rótulos e os atributos estão relacionadas segundo a equação:

$$y^{(i)} = \theta^T x^{(i)} + \epsilon^{(i)}$$

- ϵ é o erro que captura informação de atributos não modelados ou ruído.

Regressão linear

$$h(x) = \sum_{i=0}^n \theta_i x_i = \theta^T x$$

$$J(\theta) = \frac{1}{2} \sum_{i=1}^m (h_{\theta}(x^{(i)}) - y^{(i)})^2$$

Porque regressão linear com uma função de custo de mínimos quadrados é uma escolha razoável?

Suponha que os rótulos e os atributos estão relacionadas segundo a equação:

$$y^{(i)} = \theta^T x^{(i)} + \epsilon^{(i)}$$

- ϵ é o erro que captura informação de atributos não modelados ou ruído.

A regressão passa a modelar **uma distribuição para y** e não apenas um valor determinístico

Regressão linear

$$h(x) = \sum_{i=0}^n \theta_i x_i = \theta^T x$$

$$J(\theta) = \frac{1}{2} \sum_{i=1}^m (h_{\theta}(x^{(i)}) - y^{(i)})^2$$

Porque regressão linear com uma função de custo de mínimos quadrados é uma escolha razoável?

Suponha que os rótulos e os atributos estão relacionadas segundo a equação:

$$y^{(i)} = \theta^T x^{(i)} + \epsilon^{(i)}$$

- ϵ é o erro que captura informação de atributos não modelados ou ruído.
- ϵ segue uma distribuição Gaussiana (distribuição Normal) com média $\mu=0$ e alguma variância σ

A função densidade de probabilidade da distribuição normal é assim definida:

$$f(x, \mu, \sigma) = \frac{1}{\sqrt{2\pi\sigma^2}} e^{\left(-\frac{(x-\mu)^2}{2\sigma^2}\right)}$$

Regressão linear

$$h(x) = \sum_{i=0}^n \theta_i x_i = \theta^T x$$

$$J(\theta) = \frac{1}{2} \sum_{i=1}^m (h_{\theta}(x^{(i)}) - y^{(i)})^2$$

Porque regressão linear com uma função de custo de mínimos quadrados é uma escolha razoável?

Suponha que os rótulos e os atributos estão relacionadas segundo a equação:

$$y^{(i)} = \theta^T x^{(i)} + \epsilon^{(i)}$$

- ϵ é o erro que captura informação de atributos não modelados ou ruído.
- ϵ segue uma distribuição Gaussiana (distribuição Normal) com média $\mu=0$ e alguma variância σ

$$p(\epsilon^{(i)}) = \frac{1}{\sqrt{2\pi}\sigma} \exp\left(-\frac{(\epsilon^{(i)})^2}{2\sigma^2}\right)$$

Regressão linear

$$h(x) = \sum_{i=0}^n \theta_i x_i = \theta^T x$$

$$J(\theta) = \frac{1}{2} \sum_{i=1}^m (h_{\theta}(x^{(i)}) - y^{(i)})^2$$

Porque regressão linear com uma função de custo de mínimos quadrados é uma escolha razoável?

Suponha que os rótulos e os atributos estão relacionadas segundo a equação:

$$y^{(i)} = \theta^T x^{(i)} + \epsilon^{(i)} \quad (1)$$

- ϵ é o erro que captura informação de atributos não modelados ou ruído.
- ϵ segue uma distribuição Gaussiana (distribuição Normal) com média $\mu=0$ e alguma variância σ

$$p(\epsilon^{(i)}) = \frac{1}{\sqrt{2\pi}\sigma} \exp\left(-\frac{(\epsilon^{(i)})^2}{2\sigma^2}\right)$$

que implica em:

$$p(y^{(i)}|x^{(i)}; \theta) = \frac{1}{\sqrt{2\pi}\sigma} \exp\left(-\frac{(y^{(i)} - \theta^T x^{(i)})^2}{2\sigma^2}\right) \quad (2)$$

Regressão linear

$$h(x) = \sum_{i=0}^n \theta_i x_i = \theta^T x$$

$$J(\theta) = \frac{1}{2} \sum_{i=1}^m (h_{\theta}(x^{(i)}) - y^{(i)})^2$$

Porque regressão linear com uma função de custo de mínimos quadrados é uma escolha razoável?

Suponha que os rótulos e os atributos estão relacionadas segundo a equação:

$$y^{(i)} = \theta^T x^{(i)} + \epsilon^{(i)}$$

- ϵ é o erro que captura informação de atributos não modelados ou ruído.
- ϵ segue uma distribuição Gaussiana (distribuição normal) com média $\mu=0$ e alguma variância σ

$$p(\epsilon^{(i)}) = \frac{1}{\sqrt{2\pi}\sigma} \exp\left(-\frac{(\epsilon^{(i)})^2}{2\sigma^2}\right)$$

Distribuição de $y^{(i)}$ dado $x^{(i)}$ e parametrizada por θ . Também chamada de probabilidade dos dados.

que implica em:

$$p(y^{(i)}|x^{(i)}; \theta) = \frac{1}{\sqrt{2\pi}\sigma} \exp\left(-\frac{(y^{(i)} - \theta^T x^{(i)})^2}{2\sigma^2}\right)$$

Regressão linear

$$h(x) = \sum_{i=0}^n \theta_i x_i = \theta^T x$$

$$J(\theta) = \frac{1}{2} \sum_{i=1}^m (h_{\theta}(x^{(i)}) - y^{(i)})^2$$

Porque regressão linear com uma função de custo de mínimos quadrados é uma escolha razoável?

Suponha que os rótulos e os atributos estão relacionadas segundo a equação:

$$y^{(i)} = \theta^T x^{(i)} + \epsilon^{(i)}$$

- ϵ é o erro que captura informação de atributos não modelados ou ruído.
- ϵ segue uma distribuição Gaussiana (distribuição Normal) com média $\mu=0$ e alguma variância σ

$$p(\epsilon^{(i)}) = \frac{1}{\sqrt{2\pi}\sigma} \exp\left(-\frac{(\epsilon^{(i)})^2}{2\sigma^2}\right)$$

que implica em:

$$p(y^{(i)}|x^{(i)}; \theta) = \frac{1}{\sqrt{2\pi}\sigma} \exp\left(-\frac{(y^{(i)} - \theta^T x^{(i)})^2}{2\sigma^2}\right)$$

Note que p é uma função que depende de y , para valores fixos de θ .

Regressão linear

$$h(x) = \sum_{i=0}^n \theta_i x_i = \theta^T x$$

$$J(\theta) = \frac{1}{2} \sum_{i=1}^m (h_{\theta}(x^{(i)}) - y^{(i)})^2$$

Porque regressão linear com uma função de custo de mínimos quadrados é uma escolha razoável?

Suponha que os rótulos e os atributos estão relacionadas segundo a equação:

$$y^{(i)} = \theta^T x^{(i)} + \epsilon^{(i)}$$

- ϵ é o erro que captura informação de atributos não modelados ou ruído.
- ϵ segue uma distribuição Gaussiana (distribuição Normal) com média $\mu=0$ e alguma variância σ

$$p(\epsilon^{(i)}) = \frac{1}{\sqrt{2\pi}\sigma} \exp\left(-\frac{(\epsilon^{(i)})^2}{2\sigma^2}\right)$$

que implica em:

$$p(y^{(i)}|x^{(i)}; \theta) = \frac{1}{\sqrt{2\pi}\sigma} \exp\left(-\frac{(y^{(i)} - \theta^T x^{(i)})^2}{2\sigma^2}\right)$$

Intuitivamente:
Qual a chance de observar esses dados se o parâmetro for θ ?

Regressão linear

Se desejamos explicitamente interpretar essa função anterior como uma função de θ , chamamos essa função de Verossimilhança (Likelihood):

$$L(\theta) = L(\theta; X, \vec{y}) = p(\vec{y}|X; \theta)$$

Regressão linear

Se desejamos explicitamente interpretar essa função anterior como uma função de θ , chamamos essa função de Verossimilhança.

$$L(\theta) = L(\theta; X, \vec{y}) = p(\vec{y}|X; \theta)$$

Intuitivamente:

Qual valor de θ explica melhor os dados que observei?

A função de verossimilhança é usada para estimar quais parâmetros tornam os dados mais plausíveis

Regressão linear

$$p(y^{(i)}|x^{(i)}; \theta) = \frac{1}{\sqrt{2\pi}\sigma} \exp\left(-\frac{(y^{(i)} - \theta^T x^{(i)})^2}{2\sigma^2}\right)$$

Se desejamos explicitamente interpretar essa função anterior como uma função de θ , chamamos essa função de Verossimilhança (Likelihood):

$$L(\theta) = L(\theta; X, \vec{y}) = p(\vec{y}|X; \theta)$$

pela suposição de independência na geração dos m exemplos de treinamento:

$$L(\theta) = \prod_{i=1}^m p(y^{(i)} | x^{(i)}; \theta)$$

Regressão linear

$$p(y^{(i)}|x^{(i)}; \theta) = \frac{1}{\sqrt{2\pi}\sigma} \exp\left(-\frac{(y^{(i)} - \theta^T x^{(i)})^2}{2\sigma^2}\right)$$

Se desejamos explicitamente interpretar essa função anterior como uma função de θ , chamamos essa função de Verossimilhança (Likelihood):

$$L(\theta) = L(\theta; X, \vec{y}) = p(\vec{y}|X; \theta)$$

pela suposição de independência na geração dos m exemplos de treinamento:

$$\begin{aligned} L(\theta) &= \prod_{i=1}^m p(y^{(i)} | x^{(i)}; \theta) \\ &= \prod_{i=1}^m \frac{1}{\sqrt{2\pi}\sigma} \exp\left(-\frac{(y^{(i)} - \theta^T x^{(i)})^2}{2\sigma^2}\right) \end{aligned}$$

Regressão linear

Se desejamos explicitamente interpretar essa função anterior como uma função de θ , chamamos essa função de Verossimilhança (Likelihood):

$$L(\theta) = L(\theta; X, \vec{y}) = p(\vec{y}|X; \theta)$$

pela suposição de independência na geração dos m exemplos de treinamento:

$$\begin{aligned} L(\theta) &= \prod_{i=1}^m p(y^{(i)} | x^{(i)}; \theta) \\ &= \prod_{i=1}^m \frac{1}{\sqrt{2\pi}\sigma} \exp\left(-\frac{(y^{(i)} - \theta^T x^{(i)})^2}{2\sigma^2}\right) \end{aligned}$$

Um dos métodos estatísticos para estimar os parâmetros é a estimativa de máxima verossimilhança (M.L.E. - maximum likelihood estimator). Devemos escolher θ tal que os dados tenham a maior probabilidade possível, isto é, escolher θ que maximiza $L(\theta)$.

Regressão linear

Para fazer os cálculos mais simples, no lugar de maximizar $L(\theta)$ podemos maximizar o log de $L(\theta)$:

$$\ell(\theta) = \log L(\theta)$$

Regressão linear

$$L(\theta) = \prod_{i=1}^m \frac{1}{\sqrt{2\pi}\sigma} \exp\left(-\frac{(y^{(i)} - \theta^T x^{(i)})^2}{2\sigma^2}\right)$$

Para fazer os cálculos mais simples, no lugar de maximizar $L(\theta)$ podemos maximizar o log de $L(\theta)$:

$$\ell(\theta) = \log L(\theta)$$

Regressão linear

$$L(\theta) = \prod_{i=1}^m \frac{1}{\sqrt{2\pi}\sigma} \exp\left(-\frac{(y^{(i)} - \theta^T x^{(i)})^2}{2\sigma^2}\right)$$

Para fazer os cálculos mais simples, no lugar de maximizar $L(\theta)$ podemos maximizar o log de $L(\theta)$:

$$\begin{aligned}\ell(\theta) &= \log L(\theta) \\ &= \log \prod_{i=1}^m \frac{1}{\sqrt{2\pi}\sigma} \exp\left(-\frac{(y^{(i)} - \theta^T x^{(i)})^2}{2\sigma^2}\right)\end{aligned}$$

Regressão linear

$$L(\theta) = \prod_{i=1}^m \frac{1}{\sqrt{2\pi}\sigma} \exp\left(-\frac{(y^{(i)} - \theta^T x^{(i)})^2}{2\sigma^2}\right)$$

Para fazer os cálculos mais simples, no lugar de maximizar $L(\theta)$ podemos maximizar o log de $L(\theta)$:

PROPRIEDADES DOS LOGARITMOS

$$1) \log_a b \cdot c = \log_a b + \log_a c$$

$$2) \log_a \left(\frac{b}{c}\right) = \log_a b - \log_a c$$

$$3) \log_a b^a = a \cdot \log_a b$$

$$4) \log_{a^x} b = \frac{1}{x} \cdot \log_a b$$

$$\begin{aligned} \ell(\theta) &= \log L(\theta) \\ &= \log \prod_{i=1}^m \frac{1}{\sqrt{2\pi}\sigma} \exp\left(-\frac{(y^{(i)} - \theta^T x^{(i)})^2}{2\sigma^2}\right) \end{aligned}$$

Regressão linear

Para fazer os cálculos mais simples, no lugar de maximizar $L(\theta)$ podemos maximizar o log de $L(\theta)$:

PROPRIEDADES DOS LOGARITMOS

$$1) \log_a b \cdot c = \log_a b + \log_a c$$

$$2) \log_a \left(\frac{b}{c}\right) = \log_a b - \log_a c$$

$$3) \log_a b^a = a \cdot \log_a b$$

$$4) \log_{a^x} b = \frac{1}{x} \cdot \log_a b$$

$$\begin{aligned}\ell(\theta) &= \log L(\theta) \\ &= \log \prod_{i=1}^m \frac{1}{\sqrt{2\pi}\sigma} \exp\left(-\frac{(y^{(i)} - \theta^T x^{(i)})^2}{2\sigma^2}\right) \\ &= \sum_{i=1}^m \log \frac{1}{\sqrt{2\pi}\sigma} \exp\left(-\frac{(y^{(i)} - \theta^T x^{(i)})^2}{2\sigma^2}\right) \\ &= m \log \frac{1}{\sqrt{2\pi}\sigma} - \frac{1}{\sigma^2} \cdot \frac{1}{2} \sum_{i=1}^m (y^{(i)} - \theta^T x^{(i)})^2\end{aligned}$$

Regressão linear

Para fazer os cálculos mais simples, no lugar de maximizar $L(\theta)$ podemos maximizar o log de $L(\theta)$:

$$\begin{aligned}\ell(\theta) &= \log L(\theta) \\ &= \log \prod_{i=1}^m \frac{1}{\sqrt{2\pi}\sigma} \exp\left(-\frac{(y^{(i)} - \theta^T x^{(i)})^2}{2\sigma^2}\right) \\ &= \sum_{i=1}^m \log \frac{1}{\sqrt{2\pi}\sigma} \exp\left(-\frac{(y^{(i)} - \theta^T x^{(i)})^2}{2\sigma^2}\right) \\ &= m \cancel{\log \frac{1}{\sqrt{2\pi}\sigma}} - \cancel{\frac{1}{\sigma^2}} \cdot \frac{1}{2} \sum_{i=1}^m (y^{(i)} - \theta^T x^{(i)})^2\end{aligned}$$

maximizar $\ell(\theta)$ é o mesmo que

Regressão linear

Para fazer os cálculos mais simples, no lugar de maximizar $L(\theta)$ podemos maximizar o log de $L(\theta)$:

$$\begin{aligned}\ell(\theta) &= \log L(\theta) \\ &= \log \prod_{i=1}^m \frac{1}{\sqrt{2\pi}\sigma} \exp \left(-\frac{(y^{(i)} - \theta^T x^{(i)})^2}{2\sigma^2} \right) \\ &= \sum_{i=1}^m \log \frac{1}{\sqrt{2\pi}\sigma} \exp \left(-\frac{(y^{(i)} - \theta^T x^{(i)})^2}{2\sigma^2} \right) \\ &= \cancel{m \log \frac{1}{\sqrt{2\pi}\sigma}} - \cancel{\frac{1}{\sigma^2}} \cdot \frac{1}{2} \sum_{i=1}^m (y^{(i)} - \theta^T x^{(i)})^2\end{aligned}$$

maximizar $\ell(\theta)$ é o mesmo que minimizar:

$$\frac{1}{2} \sum_{i=1}^m (y^{(i)} - \theta^T x^{(i)})^2$$

Regressão linear

$$J(\theta) = \frac{1}{2} \sum_{i=1}^m (h_{\theta}(x^{(i)}) - y^{(i)})^2$$

Para fazer os cálculos mais simples, no lugar de maximizar $L(\theta)$ podemos maximizar o log de $L(\theta)$:

$$\begin{aligned} \ell(\theta) &= \log L(\theta) \\ &= \log \prod_{i=1}^m \frac{1}{\sqrt{2\pi}\sigma} \exp \left(-\frac{(y^{(i)} - \theta^T x^{(i)})^2}{2\sigma^2} \right) \\ &= \sum_{i=1}^m \log \frac{1}{\sqrt{2\pi}\sigma} \exp \left(-\frac{(y^{(i)} - \theta^T x^{(i)})^2}{2\sigma^2} \right) \\ &= \cancel{m \log \frac{1}{\sqrt{2\pi}\sigma}} - \cancel{\frac{1}{\sigma^2}} \cdot \frac{1}{2} \sum_{i=1}^m (y^{(i)} - \theta^T x^{(i)})^2 \end{aligned}$$

maximizar $\ell(\theta)$ é o mesmo que minimizar:

$$\frac{1}{2} \sum_{i=1}^m (y^{(i)} - \theta^T x^{(i)})^2$$

Regressão linear

$$J(\theta) = \frac{1}{2} \sum_{i=1}^m (h_{\theta}(x^{(i)}) - y^{(i)})^2$$

Para fazer os cálculos mais simples, no lugar de maximizar $L(\theta)$ podemos maximizar o log de $L(\theta)$:

$$\begin{aligned}\ell(\theta) &= \log L(\theta) \\ &= \log \prod_{i=1}^m \frac{1}{\sqrt{2\pi}\sigma} \exp\left(-\frac{(y^{(i)} - \theta^T x^{(i)})^2}{2\sigma^2}\right) \\ &= \sum_{i=1}^m \log \frac{1}{\sqrt{2\pi}\sigma} \exp\left(-\frac{(y^{(i)} - \theta^T x^{(i)})^2}{2\sigma^2}\right) \\ &= \cancel{m \log \frac{1}{\sqrt{2\pi}\sigma}} - \cancel{\frac{1}{\sigma^2}} \cdot \frac{1}{2} \sum_{i=1}^m (y^{(i)} - \theta^T x^{(i)})^2\end{aligned}$$

maximizar $\ell(\theta)$ é o mesmo que minimizar:

$$\frac{1}{2} \sum_{i=1}^m (y^{(i)} - \theta^T x^{(i)})^2$$

Considerando as suposições probabilísticas sobre os dados, a regressão de mínimos quadrados é o mesmo que encontrar a estimativa de máxima verossimilhança de θ

Classificação e regressão logística

Classificação e regressão logística


- Forma da hipótese de regressão linear:

$$h(x) = \sum_{i=0}^n \theta_i x_i = \theta^T x$$

- Poderíamos usar regressão linear para o problema de classificação binária. Porém, não faz sentido obter hipóteses $h(x)$ com valores maiores do que 1 ou menores do que 0.
- Podemos usar uma outra forma de hipóteses.

Função logística

- É uma função sigmoide
- É derivável em todos seus pontos
- A saída está entre 0 e 1



$$g(z) = \frac{1}{1 + e^{-z}}$$

$$g'(z) = g(z)(1 - g(z))$$

Classificação e regressão logística

- Forma de hipótese da regressão logística

$$h_{\theta}(x) = g(\theta^T x) = \frac{1}{1 + e^{-\theta^T x}},$$

$$g(z) = \frac{1}{1 + e^{-z}}$$

Regressão logística

- Como ajustar θ ?
- Definir suposições probabilísticas para o modelo de classificação
- Ajustar os parâmetros com o estimador de máxima verossimilhança

Regressão logística

- Suponha que os dados seguem a seguinte distribuição

$$\begin{aligned}P(y = 1 \mid x; \theta) &= h_{\theta}(x) \\P(y = 0 \mid x; \theta) &= 1 - h_{\theta}(x)\end{aligned}$$


Regressão logística

- Suponha que os dados seguem a seguinte distribuição

$$\begin{aligned}P(y = 1 \mid x; \theta) &= h_{\theta}(x) \\P(y = 0 \mid x; \theta) &= 1 - h_{\theta}(x)\end{aligned}$$

$$h_{\theta}(x) = g(\theta^T x) = \frac{1}{1 + e^{-\theta^T x}},$$

Se $\theta^T x = 2$, a
probabilidade de ser um
exemplo positivo é 0.881




Regressão logística

- Suponha que os dados seguem a seguinte distribuição

$$\begin{aligned}P(y = 1 \mid x; \theta) &= h_{\theta}(x) \\P(y = 0 \mid x; \theta) &= 1 - h_{\theta}(x)\end{aligned}$$

$$h_{\theta}(x) = g(\theta^T x) = \frac{1}{1 + e^{-\theta^T x}},$$

Regressão Logística + limiar
fornece um classificador.
Ex: se $g(\theta^T x) \geq 0.5$ então
é um exemplo positivo, caso
contrário é negativo.




Regressão logística

$$\begin{aligned}P(y = 1 \mid x; \theta) &= h_{\theta}(x) \\P(y = 0 \mid x; \theta) &= 1 - h_{\theta}(x)\end{aligned}$$

- Suponha que os dados seguem a seguinte distribuição:

$$h_{\theta}(x) = g(\theta^T x) = \frac{1}{1 + e^{-\theta^T x}},$$

Suponha que:
se $g(\theta^T x) \geq 0.5$ então $y=1$,
caso contrário $y=0$



Regressão logística


$$\begin{aligned}P(y = 1 \mid x; \theta) &= h_{\theta}(x) \\P(y = 0 \mid x; \theta) &= 1 - h_{\theta}(x)\end{aligned}$$

- Suponha que os dados seguem a seguinte distribuição:

$$h_{\theta}(x) = g(\theta^T x) = \frac{1}{1 + e^{-\theta^T x}},$$

Se $\theta^T x \geq 0$ então $y=1$
caso contrário $y=0$

Suponha que:
se $g(\theta^T x) \geq 0.5$ então $y=1$,
caso contrário $y=0$




Regressão logística

- Suponha que os dados seguem a seguinte distribuição:

$$h_{\theta}(x) = g(\theta^T x) = \frac{1}{1 + e^{-\theta^T x}},$$

Se $\theta^T x \geq 0$ então $y=1$
caso contrário $y=0$


<https://www.youtube.com/watch?v=4u81xU7BIOc&t=1522s>



$$h_{\theta}(x) = g(\theta_0 + \theta_1 x_1 + \theta_2 x_2)$$

$$\begin{aligned} P(y = 1 \mid x; \theta) &= h_{\theta}(x) \\ P(y = 0 \mid x; \theta) &= 1 - h_{\theta}(x) \end{aligned}$$

Suponha que:
se $g(\theta^T x) \geq 0.5$ então $y=1$,
caso contrário $y=0$



Regressão logística


$$\begin{aligned}P(y = 1 \mid x; \theta) &= h_{\theta}(x) \\P(y = 0 \mid x; \theta) &= 1 - h_{\theta}(x)\end{aligned}$$

- Suponha que os dados seguem a seguinte distribuição:

$$h_{\theta}(x) = g(\theta^T x) = \frac{1}{1 + e^{-\theta^T x}},$$

Se $\theta^T x \geq 0$ então $y=1$
caso contrário $y=0$


<https://www.youtube.com/watch?v=4u81xU7BIOc&t=1522s>



$$h_{\theta}(x) = g(\theta_0 + \theta_1 x_1 + \theta_2 x_2)$$

$$\theta^T x = -3 + 1x_1 + 1x_2$$

Suponha que:
se $g(\theta^T x) \geq 0.5$ então $y=1$,
caso contrário $y=0$



Regressão logística


$$\begin{aligned}P(y = 1 \mid x; \theta) &= h_{\theta}(x) \\P(y = 0 \mid x; \theta) &= 1 - h_{\theta}(x)\end{aligned}$$

- Suponha que os dados seguem a seguinte distribuição:

$$h_{\theta}(x) = g(\theta^T x) = \frac{1}{1 + e^{-\theta^T x}},$$

Se $\theta^T x \geq 0$ então $y=1$
caso contrário $y=0$

<https://www.youtube.com/watch?v=4u81xU7BIOc&t=1522s>




$$h_{\theta}(x) = g(\theta_0 + \theta_1 x_1 + \theta_2 x_2)$$

$$\theta^T x = -3 + 1x_1 + 1x_2$$

$$\begin{aligned}-3 + 1x_1 + 1x_2 &= 0 \\1x_1 + 1x_2 &= 3\end{aligned}$$

Suponha que:
se $g(\theta^T x) \geq 0.5$ então $y=1$,
caso contrário $y=0$



Regressão logística


$$P(y = 1 \mid x; \theta) = h_{\theta}(x)$$
$$P(y = 0 \mid x; \theta) = 1 - h_{\theta}(x)$$

- Suponha que os dados seguem a seguinte distribuição:

$$h_{\theta}(x) = g(\theta^T x) = \frac{1}{1 + e^{-\theta^T x}},$$

Se $\theta^T x \geq 0$ então $y=1$
caso contrário $y=0$

<https://www.youtube.com/watch?v=4u81xU7BIOc&t=1522s>




$$h_{\theta}(x) = g(\theta_0 + \theta_1 x_1 + \theta_2 x_2)$$

$$\theta^T x = -3 + 1x_1 + 1x_2$$

Decision Boundary
 $-3 + 1x_1 + 1x_2 = 0$
 $1x_1 + 1x_2 = 3$

Suponha que:
se $g(\theta^T x) \geq 0.5$ então $y=1$,
caso contrário $y=0$



Regressão logística

- Suponha que os dados seguem a seguinte distribuição

$$\begin{aligned}P(y = 1 \mid x; \theta) &= h_{\theta}(x) \\P(y = 0 \mid x; \theta) &= 1 - h_{\theta}(x)\end{aligned}$$

- Representando o mesmo, mas de maneira compacta:

$$p(y \mid x; \theta) = (h_{\theta}(x))^y (1 - h_{\theta}(x))^{1-y}$$

Regressão logística

- Suponha que os dados seguem a seguinte distribuição

$$\begin{aligned}P(y = 1 \mid x; \theta) &= h_{\theta}(x) \\P(y = 0 \mid x; \theta) &= 1 - h_{\theta}(x)\end{aligned}$$

- Representando o mesmo, mas de maneira compacta:

$$p(y \mid x; \theta) = (h_{\theta}(x))^y (1 - h_{\theta}(x))^{1-y}$$

- Supondo que os m exemplos de treinamento são gerados independentemente, a verossimilhança dos parâmetros é:

$$\begin{aligned}L(\theta) &= p(\vec{y} \mid X; \theta) \\&= \prod_{i=1}^m p(y^{(i)} \mid x^{(i)}; \theta)\end{aligned}$$

Regressão logística

- Suponha que os dados seguem a seguinte distribuição

$$\begin{aligned}P(y = 1 \mid x; \theta) &= h_{\theta}(x) \\P(y = 0 \mid x; \theta) &= 1 - h_{\theta}(x)\end{aligned}$$

- Representando o mesmo, mas de maneira compacta:

$$p(y \mid x; \theta) = (h_{\theta}(x))^y (1 - h_{\theta}(x))^{1-y}$$

- Supondo que os m exemplos de treinamento são gerados independentemente, a verossimilhança dos parâmetros é:

$$\begin{aligned}L(\theta) &= p(\vec{y} \mid X; \theta) \\&= \prod_{i=1}^m p(y^{(i)} \mid x^{(i)}; \theta) \\&= \prod_{i=1}^m (h_{\theta}(x^{(i)}))^{y^{(i)}} (1 - h_{\theta}(x^{(i)}))^{1-y^{(i)}}\end{aligned}$$

Regressão logística

- É mais fácil trabalhar com o log da verossimilhança:

$$\ell(\theta) = \log L(\theta)$$

Regressão logística

- É mais fácil trabalhar com o log da verossimilhança:

$$\ell(\theta) = \log L(\theta)$$

PROPRIEDADES DOS LOGARITMOS

$$1) \log_a b \cdot c = \log_a b + \log_a c$$

$$2) \log_a \left(\frac{b}{c}\right) = \log_a b - \log_a c$$

$$3) \log_a b^a = a \cdot \log_a b$$

$$4) \log_{a^x} b = \frac{1}{x} \cdot \log_a b$$

$$\begin{aligned} L(\theta) &= p(\vec{y} \mid X; \theta) \\ &= \prod_{i=1}^m p(y^{(i)} \mid x^{(i)}; \theta) \\ &= \prod_{i=1}^m (h_{\theta}(x^{(i)}))^{y^{(i)}} (1 - h_{\theta}(x^{(i)}))^{1-y^{(i)}} \end{aligned}$$

Regressão logística

- É mais fácil trabalhar com o log da verossimilhança:

$$\begin{aligned}\ell(\theta) &= \log L(\theta) \\ &= \sum_{i=1}^m y^{(i)} \log h(x^{(i)}) + (1 - y^{(i)}) \log(1 - h(x^{(i)}))\end{aligned}$$

Regressão logística

- É mais fácil trabalhar com o log da verossimilhança:

$$\begin{aligned}\ell(\theta) &= \log L(\theta) \\ &= \sum_{i=1}^m y^{(i)} \log h(x^{(i)}) + (1 - y^{(i)}) \log(1 - h(x^{(i)}))\end{aligned}$$

- Para maximizar o $\ell(\theta)$ pode ser usado o gradiente ascendente

$$\theta := \theta + \alpha \nabla_{\theta} \ell(\theta)$$

Regressão logística

$$\begin{aligned}\ell(\theta) &= \log L(\theta) \\ &= \sum_{i=1}^m y^{(i)} \log h(x^{(i)}) + (1 - y^{(i)}) \log(1 - h(x^{(i)}))\end{aligned}$$

- Considerando apenas um exemplo de treinamento

$$h_{\theta}(x) = g(\theta^T x) = \frac{1}{1 + e^{-\theta^T x}},$$

$$l(\theta) = y \log g(\theta^T \mathbf{x}) + (1-y) \log (1-g(\theta^T \mathbf{x}))$$

Derivada da função logarítmica

$$f(x) = \ln(x)$$

$$f'(x) = \frac{1}{x}$$

Regressão logística

$$\begin{aligned}\ell(\theta) &= \log L(\theta) \\ &= \sum_{i=1}^m y^{(i)} \log h(x^{(i)}) + (1 - y^{(i)}) \log(1 - h(x^{(i)}))\end{aligned}$$

- Considerando apenas um exemplo de treinamento

$$h_{\theta}(x) = g(\theta^T x) = \frac{1}{1 + e^{-\theta^T x}},$$

$$l(\theta) = y \log g(\theta^T x) + (1-y) \log (1-g(\theta^T x))$$

$$\frac{\partial}{\partial \theta_j} \ell(\theta) = \left(y \frac{1}{g(\theta^T x)} - (1-y) \frac{1}{1 - g(\theta^T x)} \right) \frac{\partial}{\partial \theta_j} g(\theta^T x)$$

Regressão logística

$$\begin{aligned}\ell(\theta) &= \log L(\theta) \\ &= \sum_{i=1}^m y^{(i)} \log h(x^{(i)}) + (1 - y^{(i)}) \log(1 - h(x^{(i)}))\end{aligned}$$

- Considerando apenas um exemplo de treinamento

$$h_{\theta}(x) = g(\theta^T x) = \frac{1}{1 + e^{-\theta^T x}},$$

$$l(\theta) = y \log g(\theta^T x) + (1-y) \log (1-g(\theta^T x))$$

$$g'(z) = g(z)(1 - g(z))$$

$$\begin{aligned}\frac{\partial}{\partial \theta_j} \ell(\theta) &= \left(y \frac{1}{g(\theta^T x)} - (1 - y) \frac{1}{1 - g(\theta^T x)} \right) \frac{\partial}{\partial \theta_j} g(\theta^T x) \\ &= \left(y \frac{1}{g(\theta^T x)} - (1 - y) \frac{1}{1 - g(\theta^T x)} \right) g(\theta^T x)(1 - g(\theta^T x)) \frac{\partial}{\partial \theta_j} \theta^T x\end{aligned}$$

Regressão logística

$$\begin{aligned}\ell(\theta) &= \log L(\theta) \\ &= \sum_{i=1}^m y^{(i)} \log h(x^{(i)}) + (1 - y^{(i)}) \log(1 - h(x^{(i)}))\end{aligned}$$

- Considerando apenas um exemplo de treinamento

$$h_{\theta}(x) = g(\theta^T x) = \frac{1}{1 + e^{-\theta^T x}},$$

$$l(\theta) = y \log g(\theta^T x) + (1-y) \log (1-g(\theta^T x))$$

$$g'(z) = g(z)(1 - g(z))$$

$$\begin{aligned}\frac{\partial}{\partial \theta_j} \ell(\theta) &= \left(y \frac{1}{g(\theta^T x)} - (1 - y) \frac{1}{1 - g(\theta^T x)} \right) \frac{\partial}{\partial \theta_j} g(\theta^T x) \\ &= \left(y \frac{1}{g(\theta^T x)} - (1 - y) \frac{1}{1 - g(\theta^T x)} \right) g(\theta^T x)(1 - g(\theta^T x)) \frac{\partial}{\partial \theta_j} \theta^T x\end{aligned}$$

$$\sum_{i=0}^n \theta_i x_i = \theta^T x$$

Regressão logística

$$\begin{aligned}\ell(\theta) &= \log L(\theta) \\ &= \sum_{i=1}^m y^{(i)} \log h(x^{(i)}) + (1 - y^{(i)}) \log(1 - h(x^{(i)}))\end{aligned}$$

- Considerando apenas um exemplo de treinamento

$$h_{\theta}(x) = g(\theta^T x) = \frac{1}{1 + e^{-\theta^T x}},$$

$$l(\theta) = y \log g(\theta^T x) + (1-y) \log (1-g(\theta^T x))$$

$$g'(z) = g(z)(1 - g(z))$$

$$\begin{aligned}\frac{\partial}{\partial \theta_j} \ell(\theta) &= \left(y \frac{1}{g(\theta^T x)} - (1 - y) \frac{1}{1 - g(\theta^T x)} \right) \frac{\partial}{\partial \theta_j} g(\theta^T x) \\ &= \left(y \frac{1}{g(\theta^T x)} - (1 - y) \frac{1}{1 - g(\theta^T x)} \right) g(\theta^T x)(1 - g(\theta^T x)) \frac{\partial}{\partial \theta_j} \theta^T x \\ &= (y(1 - g(\theta^T x)) - (1 - y)g(\theta^T x)) x_j \\ &= (y - h_{\theta}(x)) x_j\end{aligned}$$

Regressão logística e gradiente ascendente estocástico

$$\theta_j := \theta_j + \alpha (y^{(i)} - h_{\theta}(x^{(i)})) x_j^{(i)}$$

- A regra de atualização é similar com a regra de atualização do gradiente descendente estocástico da regressão linear. Porém, a hipótese h na regressão logística é uma função não linear.

$$h_{\theta}(x) = g(\theta^T x) = \frac{1}{1 + e^{-\theta^T x}},$$

Regressão logística e gradiente ascendente estocástico

$$\theta_j := \theta_j + \alpha (y^{(i)} - h_{\theta}(x^{(i)})) x_j^{(i)}$$

- A regra de atualização do gradiente. Porém, a hipótese não é linear.

Note que $h_{\theta}(x)$ nunca vai ser 0 ou 1, assim em cada passo de atualização sempre tomaremos uma certa quantidade de x_j ponderada pela taxa de aprendizado. O que implica que aprendemos com cada exemplo.

$$h_{\theta}(x) = g(\theta^T x) = \frac{1}{1 + e^{-\theta^T x}},$$

Regressão logística e gradiente ascendente estocástico

θ

Não existe uma equação normal para regressão logística. Precisamos usar gradiente ascendente ou o método de Newton.

O método de Newton permite fazer passos maiores do que o gradiente ascendente.

- A regra de atualização do gradiente descendente é linear. Porém, a hipótese h na regressão logística é uma função não linear.

$$h_{\theta}(x) = g(\theta^T x) = \frac{1}{1 + e^{-\theta^T x}},$$

INTELIGÊNCIA ARTIFICIAL

Interpretação probabilística da Regressão Linear

Regressão Logística

Karina Valdivia Delgado

Slides baseados nas notas do prof. Andrew Ng