

INTELIGÊNCIA ARTIFICIAL

Resumo

Karina Valdivia Delgado

Slides baseados nas notas do prof. Andrew Ng

Regressão Linear:

hipótese e função de custo

- Hipótese

$$h(x) = \sum_{i=0}^n \theta_i x_i = \theta^T x$$

- Função de custo

$$J(\theta) = \frac{1}{2} \sum_{i=1}^m (h_{\theta}(x^{(i)}) - y^{(i)})^2$$

Regressão linear: Algoritmos iterativos para encontrar θ

■ Batch gradient descent

Repeat until convergence {

$$\theta_j := \theta_j + \alpha \sum_{i=1}^m (y^{(i)} - h_{\theta}(x^{(i)})) x_j^{(i)} \quad (\text{for every } j).$$

}

■ Stochastic gradient descent

$$h(x) = \sum_{i=0}^n \theta_i x_i = \theta^T x$$

Loop {

for i=1 to m, {

$$\theta_j := \theta_j + \alpha (y^{(i)} - h_{\theta}(x^{(i)})) x_j^{(i)} \quad (\text{for every } j)$$

}

}

Regressão linear: forma fechada

- Let

$$\theta = \begin{bmatrix} \theta_0 \\ \theta_1 \\ \vdots \\ \theta_n \end{bmatrix} \quad \mathbf{X} = \begin{bmatrix} 1 & x_1^{(1)} & \dots & x_n^{(1)} \\ \vdots & \vdots & \ddots & \vdots \\ 1 & x_1^{(i)} & \dots & x_n^{(i)} \\ \vdots & \vdots & \ddots & \vdots \\ 1 & x_1^{(m)} & \dots & x_n^{(m)} \end{bmatrix}$$

$\mathbb{R}^{(n+1) \times 1}$ $\mathbb{R}^{m \times (n+1)}$

$$\mathbf{y} = \begin{bmatrix} y^{(1)} \\ y^{(2)} \\ \vdots \\ y^{(m)} \end{bmatrix}$$

Closed Form Solution:

$$\theta = (\mathbf{X}^\top \mathbf{X})^{-1} \mathbf{X}^\top \mathbf{y}$$

Regressão linear: interpretação probabilística

Suponha que os rótulos e os atributos estão relacionadas segundo a equação:

$$y^{(i)} = \theta^T x^{(i)} + \epsilon^{(i)}$$

- ϵ é o erro que captura informação de atributos não modelados ou ruído.
- ϵ segue uma distribuição Gaussiana (distribuição Normal) com média $\mu=0$ e alguma variância σ

$$p(\epsilon^{(i)}) = \frac{1}{\sqrt{2\pi}\sigma} \exp\left(-\frac{(\epsilon^{(i)})^2}{2\sigma^2}\right)$$

que implica em:

$$p(y^{(i)}|x^{(i)}; \theta) = \frac{1}{\sqrt{2\pi}\sigma} \exp\left(-\frac{(y^{(i)} - \theta^T x^{(i)})^2}{2\sigma^2}\right)$$

e desejamos explicitamente interpretar a função anterior como uma função de θ , chamamos essa função de Verossimilhança (Likelihood):

$$L(\theta) = L(\theta; X, \vec{y}) = p(\vec{y}|X; \theta)$$

Regressão linear: interpretação probabilística

Para fazer os cálculos mais simples, no lugar de maximizar $L(\theta)$ podemos maximizar o log de $L(\theta)$:

$$\begin{aligned}\ell(\theta) &= \log L(\theta) \\ &= \log \prod_{i=1}^m \frac{1}{\sqrt{2\pi}\sigma} \exp\left(-\frac{(y^{(i)} - \theta^T x^{(i)})^2}{2\sigma^2}\right) \\ &= \sum_{i=1}^m \log \frac{1}{\sqrt{2\pi}\sigma} \exp\left(-\frac{(y^{(i)} - \theta^T x^{(i)})^2}{2\sigma^2}\right) \\ &= \cancel{m \log \frac{1}{\sqrt{2\pi}\sigma}} - \cancel{\frac{1}{\sigma^2}} \cdot \frac{1}{2} \sum_{i=1}^m (y^{(i)} - \theta^T x^{(i)})^2\end{aligned}$$

maximizar $\ell(\theta)$ é o mesmo que minimizar:

$$\frac{1}{2} \sum_{i=1}^m (y^{(i)} - \theta^T x^{(i)})^2$$

Considerando as suposições probabilísticas sobre os dados, a regressão de mínimos quadrados é o mesmo que encontrar a estimativa de máxima verossimilhança de θ

Regressão logística: hipótese

- Hipótese

$$h_{\theta}(x) = g(\theta^T x) = \frac{1}{1 + e^{-\theta^T x}},$$

$$g(z) = \frac{1}{1 + e^{-z}}$$

Regressão logística

- Suponha que os dados seguem a seguinte distribuição binomial

$$\begin{aligned}P(y = 1 \mid x; \theta) &= h_{\theta}(x) \\P(y = 0 \mid x; \theta) &= 1 - h_{\theta}(x)\end{aligned}$$

- Representando o mesmo, mas de maneira compacta:

$$p(y \mid x; \theta) = (h_{\theta}(x))^y (1 - h_{\theta}(x))^{1-y}$$

- Supondo que os m exemplos de treinamento são gerados independentemente, a verossimilhança dos parâmetros é:

$$\begin{aligned}L(\theta) &= p(\vec{y} \mid X; \theta) \\&= \prod_{i=1}^m p(y^{(i)} \mid x^{(i)}; \theta) \\&= \prod_{i=1}^m (h_{\theta}(x^{(i)}))^{y^{(i)}} (1 - h_{\theta}(x^{(i)}))^{1-y^{(i)}}\end{aligned}$$

Regressão logística

- É mais fácil trabalhar com o log da verossimilhança:

$$\begin{aligned}\ell(\theta) &= \log L(\theta) \\ &= \sum_{i=1}^m y^{(i)} \log h(x^{(i)}) + (1 - y^{(i)}) \log(1 - h(x^{(i)}))\end{aligned}$$

- Para maximizar o $\ell(\theta)$ pode ser usado o gradiente ascendente

$$\theta := \theta + \alpha \nabla_{\theta} \ell(\theta)$$

Regressão logística: Algoritmo iterativo para encontrar θ

- Stochastic gradient ascent

$$\theta_j := \theta_j + \alpha (y^{(i)} - h_{\theta}(x^{(i)})) x_j^{(i)}$$

- A regra de atualização é similar com a regra de atualização do stochastic gradient descent da regressão linear.
- Porém, a hipótese h na regressão logística é uma função não linear.

$$h_{\theta}(x) = g(\theta^T x) = \frac{1}{1 + e^{-\theta^T x}},$$

Perceptron: hipótese e regras de atualização

- Hipótese

$$h_{\theta}(x) = g(\theta^T x)$$

$$g(z) = \begin{cases} 1 & \text{if } z \geq 0 \\ 0 & \text{if } z < 0 \end{cases}$$

- Regra delta de atualização

$$\theta_j := \theta_j + \alpha (y^{(i)} - h_{\theta}(x^{(i)})) x_j^{(i)}$$

- Regra simples de de atualização

$$\theta_j := \theta_j + \alpha (y^{(i)} - h_{\theta}(x^{(i)})) x_j^{(i)}$$

Perceptron

- O Perceptron é cosmeticamente semelhante à regressão linear com mínimos quadrados e regressão logística
- Porém, o Perceptron é um tipo de algoritmo muito diferente:
 - É difícil ter interpretações probabilísticas do Perceptron
 - É difícil derivar o Perceptron como um algoritmo de estimativa de máxima verossimilhança.

Exercício de regressão logística

Considere os seguintes dados de treinamento, nos quais x indica a nota de uma aluno no ENEM e y indica se um aluno ou aluna se formou ou não na universidade:

x	272	396	868	646
y	0	0	1	1

- Considere a seguinte parametrização $\theta_0 = 1$ e $\theta_1 = 0,01$ e calcule a log verosimilhança dos dados de treinamento.
- Considere $\theta_0 = 1$ e $\theta_1 = 0,01$ como valor inicial e utilize gradiente ascendente para atualizar o valor de θ . Realize quatro iterações com $\alpha = 0,1$, isto é, utilize uma vez cada exemplo de treinamento.
- Considerando o valor encontrado de θ_0 e θ_1 no item b, calcule a log verosimilhança dos dados de treinamento
- Represente os dados de treinamento em um plano cartesiano e a reta encontrada no item b.



Exercício de Perceptron

Considere os seguintes dados de treinamento, nos quais x indica a nota de uma aluno no ENEM e y indica se um aluno ou aluna se formou ou não na universidade:

x	272	396	868	646
y	0	0	1	1

- a) Represente os dados em um plano cartesiano. Os exemplos são linearmente separáveis?
- b) Considere a seguinte parametrização $\theta_0 = 1$ e $\theta_1 = 0,01$ como valor inicial e $\delta=0$, execute uma época do algoritmo de treinamento do Perceptron para atualizar o valor de θ com $\alpha = 0,1$.
- c) Represente a reta encontrada no item b, no plano cartesiano do item a


Tem um gato?




<https://www.mygreatlearning.com/blog/image-recognition/>

$$g(z) = \frac{1}{1 + e^{-z}}$$

Tem um gato/cachorro/ vaca?



<https://www.mygreatlearning.com/blog/image-recognition/>



$$g(z) = \frac{1}{1 + e^{-z}}$$

INTELIGÊNCIA ARTIFICIAL

Resumo

Karina Valdivia Delgado

Slides baseados nas notas do prof. Andrew Ng