

Análise Exploratória de Dados

- Ordenar-se em uma ordem desejável e se necessário:
- Data Wrangling: Tratamento dos dados, remoção de variáveis redundantes, correlações, ...
- Estatística Descritiva: extrair medidas como desvio padrão, média, ... (descrever)
- Visualização de Dados: criar gráficos que ajudam a entender o comportamento dos variáveis
- Reconhecimento de Padrões: aplicar técnicas de aprendizagem de máquina supervisionada para encontrar padrões

Tipos de Variáveis

Idade	Sexo	Salário	Educational
numérica	categorial	numérica	categorial
discreta	nominal	contínua	ordinal

Estatísticas Descritivas

• Medidas de Tendência Central

- média
- mediana $\rightarrow$ valor central da distribuição, 50% para um lado e 50% para o outro
- moda $\rightarrow$ até dois valores é bimodal, mais que 2 assume-se que não existe

• Medidas de dispersão

- variância/desvio padrão
- amplitude $\rightarrow$ máx - mín
- intervalo interquartil (IQR) $\rightarrow$ mostra os dados próximos a mediana, serve para o boxplot e para olhar a distribuição

Visualização de dados

- o cérebro humano interpreta mais facilmente imagens do que tabelas

Associação entre variáveis categóricas

- verificar se existe associação estatisticamente significativa entre variáveis

• teste qui-quadrado para verificar relação

- um grau de liberdade e grau de significância (geralmente 5%)

Correlação entre Variáveis Numéricas

- positiva, neutra e negativa
- correlação não implica causalidade
- existem correlações do tipo linear, não linear e não monotônica

